

Plano de transição em 6 meses para Gustavo Prado Oliveira rumo a AI/ML Engineer com foco na certificação Google Cloud Professional Machine Learning Engineer

Resumo executivo

Para o seu perfil atual, a trilha com melhor combinação de **aderência técnica, empregabilidade e aproveitamento do que você já construiu** é **AI/ML Engineer / Applied ML Engineer**, com **Research Engineer** como trilha-alvo secundária de médio prazo e **Data Scientist** como trilha adjacente, não principal. O motivo é simples: o mercado segue puxando fortemente papéis ligados a IA aplicada e big data, e o seu histórico já mostra inclinação para **modelagem, arquitetura, validação, documentos complexos e operações com LLMs**, que são muito mais centrais em AI/ML Engineering do que em um papel de Data Scientist mais analítico e menos operacional. O Fórum Econômico Mundial lista especialistas em big data e especialistas em IA/ML entre os cargos de crescimento mais acelerado até 2030, e o LinkedIn mostra que a IA está acelerando a troca de habilidades nas funções de trabalho de conhecimento. cite turn12search13 turn12search8 turn12search6

A certificação **Google Cloud Professional Machine Learning Engineer** é um alvo coerente para essa transição porque, na versão oficial vigente a partir de **1º de junho de 2026**, ela cobra exatamente o que você precisa consolidar: **soluções de IA com GenAI, BigQuery ML/AutoML, prototipação em notebooks, experimentação, treinamento e serving, pipelines, monitoramento, segurança e IA responsável**, inclusive com ênfase em **prompt/context engineering**, avaliação de GenAI e proteção contra vazamento de dados e prompt injection. A prova tem **2 horas, 50–60 questões**, custa **US\$ 200 + impostos**, não tem pré-requisito formal e segue disponível em **inglês e japonês**. O próprio Google recomenda experiência prática em GCP, mas isso é “recommended experience”, não requisito eliminatório. cite turn5search0 turn6view0

A recomendação operacional é esta: usar **conta pessoal como conta principal do Google Skills**, manter **perfil GitHub e portfólio pessoais**, e usar a conta institucional apenas quando fizer sentido para **programas acadêmicos, créditos de pesquisa ou iniciativas de faculty/research**. Isso porque as credenciais do Google Skills ficam como parte permanente da conta, podem ser compartilhadas publicamente e as contas **não podem ser mescladas**; por outro lado, o e-mail da conta **pode ser alterado** depois, o que preserva portabilidade. Além disso, o Google tem programas específicos para faculty/research com créditos e recursos adicionais. cite turn27view3 turn27view4 turn30search0 turn30search1 turn30search6

O plano abaixo assume **8–10 horas por semana** por 24 semanas. A meta

realista é tentar a prova entre as **semanas 23 e 24**, desde que você chegue a três condições: **dois projetos deployáveis, um terceiro projeto muito bem documentado**, e **média de 80% ou mais nos mocks internos**. Se ficar abaixo disso na semana 20, a melhor decisão é adiar 2–4 semanas, porque a política oficial de retake impõe espera mínima e nova cobrança. cite turn4search2 turn26search1

Posicionamento de carreira

Seu doutorado em **modelagem do estudante** e recomendação educacional te dá profundidade em formulação de problema, métricas, experimentação e interpretação. Seus projetos aplicados com **LLM para tipificação e cálculo de IRRF**, inclusive com padrões como **cache-hit, cache-miss e unique-keys**, mostram que você já pensa em **sistemas híbridos, controle operacional, latência/custo e saída estruturada**. E a experiência da entrevista/case da Cielo mostrou uma inclinação forte para **arquitetura corporativa, rastreamento, versionamento, governança do dado e preservação semântica da regra**. Em resumo: você já tem material de AI aplicada; o que falta é **embalar isso no stack cloud-native, em MLOps e em portfólio público seguro**.

A diferença prática entre os papéis pode ser sintetizada assim, a partir das descrições oficiais de **Data Scientist, Machine Learning Engineer e Research Engineer**. cite turn27view1 turn19search4 turn27view0 turn25search1

Papel	Foco principal	Entregável típico	O que mais pesa	Melhor uso para seu perfil agora
Data Scientist	Extrair insight, modelar, interpretar, comunicar	análise, modelo exploratório, dashboard, experimento	estatística, EDA, inferência, visualização, narrativa analítica	Adjacente , mas subaproveita seu lado de arquitetura e produção
AI/ML Engineer / Applied ML Engineer	Construir, empacotar, implantar, monitorar e evoluir sistemas de IA	pipeline, API, modelo em produção, monitoramento, CI/CD	software engineering, MLOps, cloud, serving, confiabilidade	Trilha principal recomendada

Papel	Foco principal	Entregável típico	O que mais pesa	Melhor uso para seu perfil agora
Research Engineer	Transformar ideia de pesquisa em sistema experimental robusto	benchmark, infra experimental, pa-per/protótipo avançado	ML profundo, engenharia de sistemas, experimentação intensiva	Trilha secundária/stretch , especialmente em EdTech, recomendação ou Document AI

A melhor leitura para você é: **Data Scientist te agrada intelectualmente, mas AI/ML Engineer te posiciona melhor no mercado e conversa melhor com o que você já fez.** Research Engineer faz sentido como extensão futura, especialmente se você quiser manter um pé forte em pesquisa aplicada, publicar e trabalhar em fronteira de modelos ou sistemas de recomendação/document understanding. O cargo de Research Engineer, nas descrições oficiais de Google DeepMind e OpenAI, demanda justamente essa ponte entre teoria, experimentação e implementação em escala. cite turn27view0 turn25search1 turn25search13

Diagnóstico de lacunas

Hoje, sua base é forte em:

- formulação de problema e pesquisa;
- IA aplicada em educação;
- raciocínio híbrido com LLM + regras;
- organização conceitual de pipelines;
- comunicação técnica e didática.

As lacunas que mais importam para virar **AI/ML Engineer GCP-ready** em 6 meses são:

- empacotamento cloud-native em GCP;
- **BigQuery / BigQuery ML / Cloud Storage / Vertex AI / Cloud Run;**
- **CI/CD** com **Cloud Build** e imagens em **Artifact Registry;**
- **orquestração** com **Vertex AI Pipelines;**
- **monitoramento**, registro, linhagem e governança;
- segurança e IA responsável em aplicações com LLM;
- portfólio público com cara de produto, e não só de pesquisa.

Competências-alvo e stack Google Cloud

A pilha que mais importa para o seu objetivo está muito alinhada à documentação oficial. O **Vertex AI** — agora evoluindo para **Gemini Enterprise Agent Platform** em partes do ecossistema — é a plataforma unificada para construir, implantar e escalar soluções de IA. O **BigQuery** é a plataforma de dados “AI-ready”, e o **BigQuery ML** permite treinar e executar modelos por SQL, inclusive integrando-se a recursos de IA. **Dataflow** faz o processamento batch/stream em escala; **Pub/Sub** viabiliza comunicação assíncrona por eventos; **Cloud Run** executa containers em modo serverless; **GKE** cobre os cenários em que você precisa de mais controle Kubernetes; **Vertex AI Pipelines** automatiza e governa workflows de ML; **Model Monitoring** acompanha qualidade/deriva; **Feature Store** gerencia e serve features; **Cloud Build** e **Artifact Registry** dão a espinha de CI/CD; **Document AI** transforma documentos não estruturados em dados estruturados; e **Model Armor** adiciona controles contra prompt injection, conteúdo nocivo e vazamento de dados em apps com LLM.

cite turn0search1 turn7search12 turn7search7 turn7search1 turn7search6 turn8search3 turn8search0 turn8search

Domínios da prova que devem guiar o plano

A nova versão oficial do guia do PMLE, válida a partir de **1º de junho de 2026**, reorganiza o exame em seis blocos que são um excelente mapa do que você precisa dominar.

cite turn6view0

Domínio do exame	Peso aproximado	O que isso significa para seu plano
Arquitetar soluções de IA low-code	13%	BigQuery ML, AutoML, seleção/avaliação de modelos, uso de APIs/Model Garden
Colaborar para gerenciar dados e modelos	16%	dados, notebooks, experimentos, avaliação, privacidade
Escalar protótipos em modelos de ML	21%	frameworks, treino, tuning, hardware
Servir e escalar modelos	20%	endpoints, Cloud Run/GKE, registry, estratégias de rollout
Automatizar e orquestrar pipelines	18%	Pipelines, CI/CD/CT, validação, reproprocessamento
Monitorar soluções de IA	13%	deriva, métricas contínuas, segurança, IA responsável

O detalhe mais importante para você é que o novo guia já fala explicitamente em **soluções baseadas em modelos fundacionais, otimização de aplicações Gemini por custo/latência/disponibilidade, LLM-as-a-judge, Model Armor, malicious prompting**, além de **prompt/context engineering**. Isso conversa diretamente com os seus projetos de LLM. cite turn6view0

Mapa de competências por papel e serviços GCP

A tabela a seguir é uma síntese prática de competências e produtos que mais importam para cada direção de carreira. Ela foi derivada das descrições oficiais de serviço do Google Cloud e das definições oficiais de função usadas acima. cite turn27view1 turn19search4 turn27view0 turn0search1 turn8search0 turn8search1 turn7search12 turn11sea

Competência	AI/ML Engineer	Data Scientist	Research Engineer	GCP mais relevante
Python e SQL	essencial	essencial	essencial	BigQuery, Colab Enterprise, Vertex AI Workbench
EDA e qualidade de dados	essencial	essencial	importante	BigQuery, Cloud Storage
BigQuery ML / prototipação low-code	essencial	essencial	opcional	BigQuery ML
Treinamento customizado	essencial	importante	essencial	Vertex AI / Agent Platform, GKE
Serving de modelos / APIs	essencial	opcional	importante	Cloud Run, Vertex AI endpoints, GKE
Pipelines e automação	essencial	opcional	importante	Vertex AI Pipelines, Cloud Build, Composer
Observabilidade e drift	essencial	importante	importante	Model Monitoring, Registry, Metadata

Competência	AI/ML Engineer	Data Scientist	Research Engineer	GCP mais relevante
GenAI/LLMs aplicados	essencial	importante	essencial	Vertex AI / Agent Platform, Model Garden, Model Armor
Document understanding	importante	opcional	importante	Document AI, BigQuery ML
Pesquisa, benchmarks e experimentação profunda	opcional	importante	essencial	Workbench, Experiments, TensorBoard, GKE

O que você precisa provar ao final de 6 meses

Ao final do ciclo, você não precisa provar “domínio total do Google Cloud”. Você precisa provar, de modo convincente, que consegue:

1. **pegar um problema real e estruturá-lo em pipeline;**
2. **treinar ou integrar um modelo de forma justificável;**
3. **implantar algo executável;**
4. **monitorar, avaliar e explicar trade-offs;**
5. **fazer isso com boa engenharia e sem risco de PI.**

Se você conseguir mostrar isso em **três projetos bem embalados**, a certificação entra como validador — não como substituto do portfólio.

Estratégia oficial de aprendizagem e decisão de conta

O eixo central do seu estudo deve ser o **learning path oficial do PMLE**, que hoje aparece com **20 atividades** no Google Skills. Como complemento, faz muito sentido usar três caminhos oficiais: **Beginner: Introduction to Generative AI** (5 atividades), **Advanced: Generative AI for Developers** (12 atividades) e **Deploy and Manage Generative AI Models** (7 atividades). O próprio Google também mantém a trilha geral de **Machine learning and AI** com cursos como **Introduction to AI and Machine Learning on Google Cloud**, além de cursos específicos de **MLOps** e materiais como o **Build a Certification Study Guide: PMLE**.

cite turn21view0 turn21view1 turn21view2 turn21view3 turn31search2 turn31search0 turn13search3 turn1view

Há um detalhe operacional importante: o Google Skills e parte da documentação estão em fase de transição de nomenclatura de **Vertex AI** para **Gemini**

Enterprise Agent Platform, e as próprias páginas oficiais alertam que você pode encontrar inconsistências nos nomes durante essa mudança. Isso importa porque você vai ver o mesmo conceito aparecer com nomes diferentes em cursos, docs e exame. cite turn21view0 turn21view1 turn21view2 turn11search2

Caminho oficial recomendado para você

Recurso oficial	Papel no plano	Prioridade
Professional Machine Learning Engineer Certification path	espinha dorsal	obrigatório
Introduction to AI and Machine Learning on Google Cloud	base unificada de produtos e lifecycle	obrigatório
Beginner: Introduction to Generative AI	consolidar vocabulário e fundamentos	muito recomendado
Advanced: Generative AI for Developers	GenAI técnico, apps, padrões	muito recomendado
Deploy and Manage Generative AI Models	MLOps de GenAI	muito recomendado
MLOps: Getting Started / Model Evaluation	fechar lacuna operacional	muito recomendado
Sample questions + exam guide + webinars	preparação de prova	obrigatório
Official Study Guide	reforço teórico estruturado	opcional, mas útil

Se você quiser manter a “porta Data Science” aberta sem desviar do objetivo principal, o melhor caminho não é trocar de trilha agora, mas adicionar um componente secundário e controlado depois do PMLE. O Google já oferece o **Associate Data Practitioner Certification** como trilha mais próxima do universo analítico, e também mantém o **Professional Data Engineer** como caminho complementar em pipelines e governança de dados. cite turn20search14 turn13search15

Conta institucional ou pessoal

Minha recomendação é: **conta pessoal como principal, conta institucional como apoio pontual.**

Opção	Vantagens	Riscos	Recomendação
Conta pessoal	portabilidade, vínculo direto com LinkedIn/GitHub, independência do empregador, preserva histórico de longo prazo	você mesmo gerencia cobrança e acesso	usar como conta principal
Conta institucional	pode facilitar uso em programas acadêmicos, faculty/research credits e iniciativas institucionais	risco de perda de acesso futuro, fragmentação de histórico se criar conta separada	usar apenas quando houver benefício institucional concreto

Essa recomendação decorre de três fatos oficiais: as credenciais do Google Skills ficam **permanentemente vinculadas à conta**, a conta pode **mudar de e-mail**, mas **duas contas não podem ser mescladas**. Ao mesmo tempo, Google Cloud mantém programas específicos para **faculty** e **researchers**, com créditos e recursos adicionais. A interface do Google Skills também permite trocar idioma para **português (Brasil)** e filtrar conteúdo por idioma, o que ajuda no estudo, embora a prova siga em inglês/japonês.

cite turn27view3 turn27view4 turn28view0 turn30search0 turn30search1 turn30search6 turn5search0

Estratégia de custo

Para reduzir custo, use três mecanismos oficiais:

1. **Google Cloud Free Trial** com **US\$ 300** de crédito para novos clientes e oferta de produtos gratuitos;
2. programas de **baixo ou nenhum custo** dentro do ecossistema de treinamento;
3. quando disponível, iniciativas como **GEAR**, que informam **35 créditos mensais** de aprendizagem no Google Skills. cite turn23search0 turn23search2 turn23search6 turn31search0

Plano de 6 meses com marcos semanais

O plano abaixo foi desenhado para o exame vigente a partir de **1º de junho de 2026** e para a sua transição específica. A lógica é: **fundação** → **projeto preditivo** → **projeto GenAI/tributário** →

projeto de documentos/regras → observabilidade e certificação.
cite turn6view0 turn21view0 turn21view2 turn21view3

gantt

```
title Transição de 6 meses para AI/ML Engineer com PMLE
dateFormat YYYY-MM-DD
axisFormat %d/%m
section Base
Fundamentos GCP + PMLE path :a1, 2026-05-18, 28d
section Projeto educacional
Student modeling baseline -> deploy :a2, 2026-06-01, 42d
section Projeto tributário
Demo IRRF LLM + regras + Cloud Run :a3, 2026-07-13, 42d
section Projeto documental
Document AI + rule extraction + diff :a4, 2026-08-24, 42d
section Certificação
Revisão PMLE + mocks + fechamento de lacunas :a5, 2026-09-28, 28d
PMLE exam :milestone, 2026-11-02, 1d
section Showcase
GitHub + LinkedIn + networking :a6, 2026-05-18, 168d
```

Mês de fundação

Semana 1

Defina os títulos-alvo do currículo e LinkedIn como: **AI Engineer**, **ML Engineer**, **Applied ML Engineer**, com **Research Engineer** como stretch. Crie a conta principal do Google Skills, ajuste idioma para pt-BR, abra seu projeto pessoal de GCP com billing controlado e monte um repositório-mãe chamado `career-transition-portfolio`.

Entregável mensurável: conta ativa, organização GitHub pronta, `roadmap.md` com 24 semanas.

Semana 2

Conclua **Introduction to AI and Machine Learning on Google Cloud**. Monte um glossário pessoal mapeando **Vertex AI**, **Gemini Enterprise Agent Platform**, **BigQuery ML**, **Cloud Run**, **Pipelines**, **Monitoring**, **Model Armor**.

Entregável mensurável: `gcp-ml-cheatsheet.md` com 2–3 páginas e mapa de serviços.

Semana 3

Faça **Beginner: Introduction to Generative AI** e execute um primeiro tutorial de **BigQuery ML** com dados públicos simples.

Entregável mensurável: notebook ou script SQL executando treino e inferência ponta a ponta.

Semana 4

Comece o **Projeto 1** com foco em student modeling: ingestão, dicionário de

dados, baseline e critérios de avaliação.

Entregável mensurável: README inicial, DATA_CARD.md, baseline reproduzível.

Mês de projeto preditivo e primeira produção

Semana 5

Aprofunde BigQuery ML e feature engineering; documente porque escolheu um baseline tabular antes de ir para algo mais sofisticado.

Entregável mensurável: script SQL ou pipeline Python que recria features e treina o modelo.

Semana 6

Implemente tracking de experimentos e compare dois modelos.

Entregável mensurável: tabela comparativa de métricas e decisão justificada do “champion model”.

Semana 7

Coloque o modelo em batch inference ou API simples. Se o deploy for via API, o default recomendado para você é **Cloud Run**, não GKE.

Entregável mensurável: endpoint funcionando, container versionado, build automatizado.

Semana 8

Faça o primeiro bloco de preparação para entrevistas: uma apresentação de 90 segundos da tese, uma de 90 segundos do app de IRRF e uma de 90 segundos do case documental/corporativo.

Entregável mensurável: arquivo interview_stories.md com 6 histórias no formato STAR.

Mês do projeto tributário com LLM

Semana 9

Conclua os módulos essenciais de **MLOps** para implantação e automação, incluindo **Cloud Build** e **Artifact Registry**.

Entregável mensurável: Dockerfile, cloudbuild.yaml, pipeline de CI funcional.

Semana 10

Inicie o **Projeto 2**: versão pública e segura do seu app de IRRF, usando **dados sintéticos** e regras reescritas do zero.

Entregável mensurável: gerador de dados sintéticos + módulo de regras determinísticas.

Semana 11

Adicione a camada LLM com padrão **cache-hit / cache-miss / unique-keys**, deixando bem explícito o que é decisão do modelo e o que é validação/regra.

Entregável mensurável: pipeline documentado, métricas de classificação, latência e taxa de cache.

Semana 12

Faça deploy da demo em **Cloud Run**, registre logs estruturados e armazene resultados agregados no **BigQuery**.

Entregável mensurável: demo API executável + dashboard simples de métricas.

Mês do projeto documental e GenAI aplicada

Semana 13

Entre na trilha **Advanced: Generative AI for Developers** e consolide padrões de prompt, grounding e avaliação.

Entregável mensurável: `genai-patterns.md` com 10 testes de prompt e critérios de aceitação.

Semana 14

Inicie prova de conceito com **Document AI** ou **ML.PROCESS_DOCUMENT** para PDFs públicos/sintéticos.

Entregável mensurável: notebook que extrai campos ou trechos estruturados de PDF.

Semana 15

Abra o **Projeto 3**, inspirado na sua experiência de case corporativo: extração de regras, normalização estruturada e comparação entre versões de documento.

Entregável mensurável: engine de comparação semântica entre duas versões de PDF ou tabela.

Semana 16

Adicione camadas de segurança e responsabilidade: políticas de dados, filtros de conteúdo, threat notes e ADRs.

Entregável mensurável: `ADR-001.md`, `ADR-002.md`, checklist de risco para cada projeto.

Mês de MLOps avançado e preparação forte para a prova

Semana 17

Conclua **Deploy and Manage Generative AI Models** e prepare um pipeline de um dos projetos com registro, avaliação e artefatos.

Entregável mensurável: especificação de pipeline e execução documentada.

Semana 18

Adicione **Model Registry**, **metadata/lineage** e **monitoramento** ao projeto mais maduro.

Entregável mensurável: captura de registry/lineage + relatório de monitoramento inicial.

Semana 19

Produza seu guia final de estudos do PMLE: matriz domínio serviço projeto dúvida. Use o recurso oficial **Build a Certification Study Guide: PMLE**

e complemente com seu próprio question bank.

Entregável mensurável: `pmle-study-guide.md` + 100 flashcards/perguntas.

Semana 20

Faça dois mocks completos.

Regra de decisão: se média $\geq 80\%$, mantenha a prova na semana 23; se $< 80\%$, remaneje a tentativa para as semanas 25–26 para evitar custo e janela de retake desnecessária.

Entregável mensurável: planilha de acertos por domínio.

Mês final de certificação, portfólio e aplicação

Semana 21

Polimento final dos repositórios que ficarão fixados no perfil.

Entregável mensurável: 3 repositórios com README forte, vídeo curto e instruções reproduzíveis.

Semana 22

Rodada 2 de preparação para entrevistas: system design de serving, trade-off **Cloud Run vs GKE**, **BigQuery ML vs custom training**, **Pipelines vs Composer**, **LLM + rule engine**.

Entregável mensurável: deck com 15 perguntas e respostas.

Semana 23

Tentativa da certificação PMLE.

Entregável mensurável: prova realizada.

Semana 24

Feche o ciclo com candidatura e networking.

Entregável mensurável: 10 aplicações customizadas, 5 mensagens de outreach, 1 post retrospectivo de ciclo.

Portfólio, projetos e GitHub sem risco de PI

Projetos recomendados

Os cinco projetos abaixo foram escolhidos para maximizar aderência ao seu histórico sem expor código, dados ou ativos sensíveis. Para os projetos educacionais, você pode usar **OULAD** e/ou **Student Performance (UCI)**. Para document understanding, **FUNSD** e **DocVQA** são boas bases públicas. cite turn24search3 turn24search1 turn24search9 turn29search2 turn29search4

Projeto	Alinhamento com seu histórico	Dados	Métricas	Entregáveis públicos seguros
Student Modeling on GCP	tese de doutorado	OULAD ou UCI Student Performance	AUC-ROC, PR-AUC, Brier/calibração, slice metrics	pipeline Big-Query/Vertex, MODEL_CARD, relatório de explicabilidade
IRRF LLM Demo	app tributário com cache-hit/cache-miss/unique-keys	sintético (NFS-e, recibos, rubricas, códigos)	macro-F1, exact match de campos, MAE/MAPE do imposto, p95 de latência, hit-rate de cache	gerador sintético, rule engine, adaptador LLM, API Cloud Run, dashboard
Rule Extraction from Public PDFs	case documental/corporativo	PDFs públicos ou sintéticos de tabelas regras/termos	precisão/recall/F1 de extração, qualidade do diff, recall@k em recuperação	Pipeline de parsing, schema de regra, comparador de versões, ADRs
Educational Recommendation API	tese + recomendação de atividades	OULAD + metadados públicos/sintéticos de materiais	NDCG@10, MAP@10, coverage/diversity	avaliador offline, API de recomendação, nota arquitetural
Document Understanding Benchmark	LLM + documentos + enterprise docs	FUNSD ou DocVQA	F1 de entidades/campos, exact match, robustez por tipo de layout	benchmark notebook, relatório comparativo, diagrama de arquitetura

Como estruturar seu GitHub

A forma mais forte para você não é despejar notebooks aleatórios, e sim montar uma **vitrine organizada por casos de uso**. Eu recomendo uma organização deste tipo:

- `gustavo-prado-ai-lab`
 - `student-modeling-gcp`

- irrf-llm-demo
- document-rule-extraction-demo
- educational-recommendation-api
- career-transition-portfolio

Cada repo deve seguir uma estrutura previsível:

```
.
  README.md
  LICENSE
  .github/workflows/
  docs/
    architecture/
    adr/
    diagrams/
  src/
  notebooks/
  infra/
  api/
  tests/
  eval/
  data/
    raw/
    synthetic/
    processed/
  MODEL_CARD.md
  DATA_CARD.md
  DISCLAIMER.md
```

O arquivo `DISCLAIMER.md` é especialmente importante no seu caso. Ele deve explicar, em linguagem clara, que:

- o projeto usa **dados públicos ou sintéticos**;
- o código foi **reescrito do zero** para fins demonstrativos;
- não há artefatos institucionais, empresariais ou protegidos;
- nomes de parceiros/clientes/casos reais foram removidos.

Template de README que funciona para seu perfil

Use sempre a mesma espinha:

1. **Problema**
2. **Por que isso importa**
3. **Escopo e o que este repo não contém**

4. **Arquitetura**
5. **Dataset**
6. **Como reproduzir**
7. **Avaliação**
8. **Resultados**
9. **Custos e limitações**
10. **Riscos, ética e segurança**
11. **Próximos passos**

Essa estrutura comunica bem tanto com recrutador técnico quanto com gerente.

Cadência de LinkedIn sem risco de IP

A melhor cadência para você é **duas postagens por mês**, durante 6 meses, sempre centradas em **aprendizado técnico + evidência pública segura**. O próprio Google Skills destaca que credenciais podem ser compartilhadas em redes sociais e que isso é positivo para distinção profissional. cite turn27view3

Sugestão de calendário:

- **Mês 1:** transição de carreira + mapa do PMLE + BigQuery ML baseline
- **Mês 2:** projeto de student modeling e por que código claro > “truques”
- **Mês 3:** arquitetura de LLM + regras + cache-hit/cache-miss
- **Mês 4:** parsing documental, regra semântica e versionamento
- **Mês 5:** MLOps, monitoramento, model registry e trade-offs
- **Mês 6:** retrospectiva do ciclo, portfólio e certificação

Formato ideal de post:

problema → abordagem → aprendizado → imagem/diagrama → link para repo

Nunca: nome de cliente, print de dado real, trecho de contrato/edital sensível, prompt interno, custos de terceiros ou código proprietário.

Certificação, entrevistas e networking

Checklist priorizado para o PMLE

A preparação mais eficiente para a certificação é fortemente “official-first”, porque o Google declara formalmente que pode atualizar o conteúdo do exame para refletir mudanças tecnológicas. cite turn26search1

Prioridade	Ação	Quando
1	Ler o guia novo do exame e transformar os 6 domínios em checklist pessoal	semana 1
2	Inscrever-se no PMLE path e cursos-base	semana 1
3	Fazer sample questions oficiais	semanas 3, 10 e 19
4	Usar o curso Build a Certification Study Guide: PMLE	semana 19
5	Revisar docs oficiais dos serviços que mais caem	contínuo
6	Fazer 2 mocks completos e revisar por domínio	semana 20
7	Agendar a prova só depois de mock estável	semana 20 ou 21
8	Fazer revisão final em inglês técnico	semanas 21–23

Seus recursos oficiais principais são: página da certificação, guia do exame, sample questions, learning path, webinars/Cloud OnAir e o study guide oficial citado pela própria página do exame. cite turn1view0 turn19search1 turn21view0 turn13search3

Dois pontos práticos merecem atenção:

- a prova está apenas em **inglês/japonês**, então seus flashcards e seu “glossário de serviços” devem estar em **inglês técnico**; cite turn5search0
- a certificação profissional vale por **2 anos**, e a política de retake exige espera mínima entre tentativas, com escalonamento do prazo em falhas subsequentes. cite turn26search1

Preparação para entrevistas

Seu diferencial não será responder trivia de serviço, e sim explicar **trade-offs**. Treine especialmente estes tópicos:

- quando usar **BigQuery ML** versus **custom training**;
- quando escolher **Cloud Run** versus **GKE**;
- como separar **extração**, **validação** e **persistência** em pipelines com LLM;
- como decidir entre **RAG**, **extração estruturada**, **rule engine** e **model serving**;
- como monitorar um modelo tabular versus uma solução com LLM;
- como expor incerteza, confiança e critérios de fallback.

Transforme seus casos em narrativas curtas:

- **tese**: “como eu modelaria estudante/risco/recomendação como sistema”;
- **IRRF**: “como eu transformei ambiguidade textual em classificação estruturada com fallback determinístico”;
- **case documental**: “como eu preservei a semântica da regra e tratei versionamento, rastreabilidade e consulta”.

Networking de maior retorno

Há cinco ambientes com melhor ROI para você:

- **Google Cloud / Developer Forums** e comunidade Google Cloud;
- **Google Developer Groups** e eventos **Build with AI**;
- **Google Cloud Innovators / Research Innovators**, quando houver janela e aderência;
- **Kaggle**, para exposição crítica e benchmark público;
- comunidades técnicas locais de Python/Dados/IA. cite turn15search5 turn15search20 turn15search2 turn15search2

Modelos curtos de outreach

Conexão inicial > Olá, [Nome]. Estou direcionando minha transição para AI/ML Engineer com foco em Google Cloud e achei seu percurso muito alinhado ao que venho construindo em modelagem educacional, LLMs aplicados e MLOps. Gostaria de acompanhar seu conteúdo e aprender com sua trajetória.

Pós-evento ou palestra > Obrigado pela palestra de hoje. O ponto sobre [tema] conversou muito com um projeto meu de [projeto]. Se fizer sentido, adoraria seguir sua trilha de materiais recomendados sobre [assunto].

Pedido de feedback técnico > Olá, [Nome]. Estruturei um pequeno projeto público em GCP sobre [tema], com foco em [objetivo]. Se você tiver 5 minutos para um feedback de alto nível sobre arquitetura ou clareza do README, eu valorizaria muito.

Riscos jurídicos, ética e propriedade intelectual

Aqui está o ponto mais sensível do seu caso.

Pelo regime jurídico do magistério federal, o regime de **40 horas com dedicação exclusiva**, em regra, implica impedimento do exercício de outra atividade remunerada. Ao mesmo tempo, o **Marco Legal de CT&I** criou hipóteses específicas para atuação do pesquisador público em atividades ligadas à pesquisa, inovação e interação com o ambiente produtivo. A aplicação concreta dessas exceções depende do vínculo, da forma de participação, da natureza da atividade e da regulamentação institucional. Por isso, o caminho seguro não é presumir permissão ampla nem proibição absoluta: é operar com **separação patrimonial, consulta formal e documentação de origem**.
cite turn18search0 turn18search1 turn18search2

No seu caso específico, o IFTM mantém **NIT** ativo e lista formalmente sua política e normas de inovação e propriedade intelectual. Além disso, a própria minuta institucional disponível ao público explicita que criadores vinculados ao IFTM devem consultar o NIT sobre a conveniência de publicar resultados de projetos de PD&I passíveis de proteção intelectual.
cite turn17view2 turn16search0 turn16search1

Riscos principais e mitigação

Risco	Impacto	Mitigação prática
Publicar código derivado de projeto institucional ou parceiro	conflito de PI / autoria / titularidade	publicar apenas versões reescritas do zero e consultar NIT/PROPI antes
Usar dados reais de municípios, estudantes ou documentos empresariais	risco de sigilo / dados sensíveis	usar dados sintéticos ou públicos anonimizados
Misturar conta pessoal e institucional em training/billing	perda de acesso / histórico fragmentado	conta pessoal principal; institucional apenas para créditos/programas específicos
Expor detalhes de caso real em GitHub/LinkedIn	risco reputacional e contratual	falar de padrão arquitetural , não de cliente, código ou dado
Usar LLM sem controles em dados sensíveis	vazamento, prompt injection, saída insegura	safety filters, revisão humana, dados sintéticos e arquitetura de proteção

No lado técnico, a própria documentação do Google deixa claro que a segurança no Vertex AI é uma **responsabilidade compartilhada**, e o **Model Armor** existe justamente para mitigar prompt injection, conteúdo inadequado e vazamento de dados em aplicações de IA; a documentação de IA responsável também descreve filtros e sinais de segurança para modelos generativos.

cite turn9search8 turn9search1 turn9search2

Regra prática para suas publicações

Antes de publicar qualquer coisa, aplique esta checklist:

- o código foi escrito por você, do zero, fora de contexto protegido?
- os dados são públicos ou sintéticos?
- existe qualquer elemento que permita inferir cliente, processo, município, disciplina, estudante ou projeto institucional específico?
- a postagem mostra **conceito/arquitetura/aprendizado**, e não ativo reaproveitável?
- houve consulta ao **NIT/PROPI** quando o material puder ter valor de PI?

Se qualquer resposta for “não” ou “talvez”, não publique ainda.

Recomendação final de trajetória

Se eu tivesse que transformar tudo isso em uma decisão de carreira objetiva, seria esta:

trilha principal: AI Engineer / ML Engineer / Applied ML Engineer

trilha secundária: Research Engineer aplicado a educação, recomendação ou document understanding

trilha adjacente: Data Scientist, mas como opção paralela e não central

O motivo não é abandonar a ciência de dados; é colocá-la **a serviço de uma trilha mais forte de entrega técnica**. Seu doutorado te dá densidade analítica. Seus projetos com LLM te dão aderência ao novo exame e ao mercado. O que mais vai mudar sua posição em 6 meses não é estudar mais teoria isolada, e sim **transformar essa base em sistemas públicos, limpos, reproduzíveis e cloud-native**. A certificação PMLE entra exatamente aí: como prova externa de que você não apenas entende IA, mas consegue **operacionalizá-la** em um stack moderno de mercado.